ISSN xxxx-xxxx

Aplikasi Web Manajemen Keuangan dengan Klasterisasi Transaksi Otomatis Menggunakan S-BERT dan K-Means

Web-Based Financial Management Application with Automatic Transaction Clustering Using S-BERT and K-Means

Pito Desri Pauzi [a,1,*]

[a] Program Studi Sarjana Terapan Teknologi Rekayasa Perangkat Lunak
Jurusan Teknologi Informasi, Politeknik Negeri Padang, Padang, Indonesia
1 pitokfauzi@gmail.com
* penulis korespondensi

ARTICLE INFO

Article history
Received
Revised
Accepted

ABSTRACT

Personal financial management is crucial for achieving financial stability, yet many users struggle with maintaining consistent records due to the tedious, manual top-down transaction categorization required by conventional applications. Existing solutions using rule-based approaches often fail to handle unstructured and varied transaction descriptions, while supervised learning methods demand massive labeled datasets that are difficult to obtain for individual users. This research proposes an unsupervised learning approach combining Natural Language Processing (NLP) to automate transaction categorization. Specifically, the Sentence-BERT (S-BERT) transformer model is implemented to extract semantic embeddings from Indonesian transaction texts, effectively capturing the conceptual intent behind varying vocabularies. Subsequently, the K-Means Clustering algorithm is applied to autonomously group these semantic vectors into personalized expense categories without requiring predefined labels. Furthermore, a Simple Moving Average (SMA) forecasting module is integrated to project monthly expenditure trends. The expected result of this study is an intelligent, web-based Personal Financial Management (PFM) application that operates bottom-up, freeing users from rigid initial categories and providing dynamic, personalized financial insights to encourage consistent financial tracking.

Keywords *: Clustering, K-Means, Personal Finance, S-BERT, Unsupervised Learning.*

ABSTRAK

Pengelolaan keuangan pribadi sangat penting untuk mencapai stabilitas finansial, namun banyak pengguna kesulitan menjaga konsistensi pencatatan karena proses kategorisasi transaksi top-down yang manual dan membosankan pada aplikasi konvensional. Solusi yang ada saat ini seperti pendekatan rule-based sering gagal menangani deskripsi transaksi yang tidak terstruktur, sementara metode supervised learning membutuhkan kumpulan data berlabel masif yang sulit diperoleh untuk pengguna individu. Penelitian ini mengusulkan pendekatan unsupervised learning yang menggabungkan Pemrosesan Bahasa Alami (NLP) untuk mengotomatisasi kategorisasi transaksi. Secara khusus, model transformer Sentence-BERT (S-BERT) diimplementasikan untuk mengekstrak embedding semantik dari teks transaksi berbahasa Indonesia, yang secara efektif menangkap niat konseptual di balik kosakata yang bervariasi. Selanjutnya, algoritma K-Means Clustering diterapkan untuk mengelompokkan vektor semantik tersebut secara mandiri ke dalam kategori pengeluaran yang personal tanpa memerlukan label yang telah ditentukan sebelumnya. Selain itu, modul peramalan Simple Moving Average (SMA) diintegrasikan untuk memproyeksikan tren pengeluaran bulanan. Hasil yang diharapkan dari penelitian ini adalah aplikasi Personal Financial Management (PFM) berbasis web cerdas yang beroperasi secara bottom-up,

membebaskan pengguna dari kategori awal yang kaku, dan memberikan wawasan keuangan yang dinamis dan personal untuk mendorong pencatatan keuangan yang konsisten.

Kata kunci : Klasterisasi, K-Means, Keuangan Pribadi, S-BERT, Unsupervised Learning.

This is an open access article under the CC–BY-SA license.

1. Pendahuluan

Pengelolaan keuangan pribadi yang efektif merupakan pondasi utama dalam mencapai stabilitas finansial. Di era digital saat ini, masyarakat semakin mengandalkan aplikasi pencatatan keuangan (Personal Financial Management / PFM) untuk melacak arus kas mereka. Meskipun demikian, efektivitas penggunaan aplikasi ini sering kali terhambat oleh proses interaksi yang membebani pengguna. Sebagian besar aplikasi konvensional masih menuntut pengguna untuk mengkategorikan setiap transaksi secara manual secara top-down (misalnya, memilih kategori "Makanan" atau "Transportasi" secara paksa). Rosidi dan Afriyudi (2023) dalam penelitiannya menyoroti bahwa proses input manual yang memakan waktu dan ketiadaan fitur otomatisasi cerdas menjadi kendala utama yang menyebabkan keengganan pengguna untuk mencatat transaksi secara rutin, yang berujung pada inkonsistensi data pengguna [1].

Berbagai pendekatan komputasi telah diusulkan untuk mengotomatisasi proses kategorisasi transaksi ini, namun masih menyisakan celah penelitian yang signifikan. Tarissa dan Dewayanto (2024) mencatat bahwa pendekatan berbasis aturan (rule-based) tradisional sering kali gagal menangani data teks transaksi pengguna yang tidak terstruktur dan sangat bervariasi [4]. Sebagai contoh, sistem rule-based kesulitan mengenali bahwa deskripsi "Beli Kopi Starbucks", "Ngopi di Janji Jiwa", dan "Traktiran Kopi Kenangan" merujuk pada intensi pengeluaran yang sama karena perbedaan struktur sintaksis. Di sisi lain, pendekatan klasifikasi supervised learning seperti yang dilakukan oleh Tandel dkk. (2021) terbukti mampu memberikan akurasi kategorisasi yang baik [5]. Akan tetapi, metode ini memiliki batasan praktis yang besar karena sangat bergantung pada ketersediaan dataset terlabel dalam jumlah masif, yang sangat sulit diperoleh karena data pengeluaran pribadi bersifat unik, rahasia, dan dinamis untuk setiap individu.

Untuk mengatasi batasan tersebut, penelitian terbaru mulai beralih ke unsupervised learning untuk menemukan pola tanpa label. Illah dkk. (2025) dan Kristanti dkk. (2024) mendemonstrasikan efektivitas K-Means Clustering untuk segmentasi data keuangan dan perilaku nasabah [6][7]. Berdasarkan celah penelitian tersebut, penelitian ini mengusulkan sebuah pendekatan unsupervised learning yang dikombinasikan dengan pemrosesan bahasa alami (Natural Language Processing/NLP). Kunci penyelesaian masalah pengenalan teks transaksi terletak pada pemahaman makna semantik, bukan sekadar pencocokan kata. Oleh karena itu, penelitian ini mengimplementasikan Sentence-BERT (S-BERT), sebuah model arsitektur transformer yang dirancang khusus untuk menghasilkan representasi vektor bernilai numerik (embeddings) dari sebuah frasa atau kalimat [2]. Melalui arsitektur siamese network, S-BERT mampu menempatkan deskripsi transaksi yang memiliki kemiripan makna konseptual secara berdekatan di dalam ruang vektor.

Setelah representasi semantik diperoleh, algoritma K-Means Clustering diterapkan untuk mempartisi dan mengelompokkan vektor-vektor transaksi tersebut secara otomatis. Sebagai fitur analitik tambahan, penelitian ini juga mengintegrasikan modul peramalan (forecasting) menggunakan metode Simple Moving Average (SMA) [9] untuk memproyeksikan tren pengeluaran bulanan.

Oleh karena itu, penelitian ini bertujuan untuk merancang dan membangun sebuah aplikasi web manajemen keuangan cerdas yang mengimplementasikan klasterisasi transaksi pengeluaran

otomatis menggunakan S-BERT dan K-Means. Kontribusi utama (novelty) dari penelitian ini adalah integrasi S-BERT dan K-Means untuk memungkinkan sistem beroperasi secara bottom-up; di mana sistem menemukan pola pengeluaran yang tersembunyi secara mandiri dan menghasilkan klaster kategori yang sangat personal bagi masing-masing pengguna, sehingga membebaskan pengguna dari keharusan membuat kategori awal yang kaku.

2. Metodologi Penelitian

Penelitian ini dilakukan melalui kerangka kerja rekayasa perangkat lunak dan machine learning yang sistematis. Fokus utama penelitian dibatasi pada pengolahan teks transaksi berbahasa Indonesia (termasuk bahasa gaul/slang) untuk transaksi pengeluaran (expenses).

2.1. Skenario Pengolahan Data

Proses pengenalan dan klasterisasi teks transaksi dilakukan melalui beberapa tahapan pipa data (pipeline) terstruktur. Secara visual, alur pemrosesan data teks (Natural Language Processing) dari masukan pengguna hingga menjadi klaster ditunjukkan pada Gambar 1.

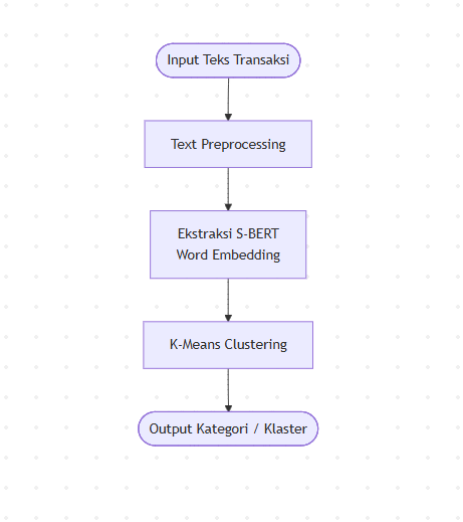

Gambar 1 Alur pemrosesan data teks transaksi (Machine Learning Pipeline)

Berdasarkan Gambar 1, tahapan tersebut dijelaskan sebagai berikut:

1. Pengumpulan dan Input Data: Data transaksi diperoleh dari input deskripsi teks pengguna secara langsung melalui antarmuka sistem (misalnya: "Beli token listrik 100k").
2. Prapemrosesan Teks (Text Preprocessing): Teks mentah dibersihkan melalui proses case folding (mengubah huruf kapital menjadi huruf kecil), cleansing (menghapus tanda baca, emoji, dan karakter khusus), serta penghapusan stop words berbahasa Indonesia agar model fokus pada kata-kata inti.
3. Ekstraksi Fitur Semantik (Embedding): Teks yang telah bersih dimasukkan ke dalam model bahasa S-BERT (varian IndoBERT yang telah di-finetune sebagai sentence transformer) untuk diubah menjadi vektor numerik berdimensi tinggi. S-BERT menggunakan komputasi Cosine Similarity dalam pelatihannya untuk memastikan bahwa teks dengan kedekatan makna konseptual (misal: "makan ayam" dan "beli sate") memiliki jarak vektor yang berdekatan dalam ruang multi-dimensi.
4. Klasterisasi (Clustering): Vektor hasil embedding dimasukkan ke dalam algoritma K-Means. Algoritma ini akan menginisialisasi titik pusat (centroid) secara acak, menghitung jarak Euclidean antara vektor transaksi ke centroid, dan mengelompokkan data ke dalam K-klaster terdekat secara iteratif hingga konvergen.

2.2. Peramalan (Forecasting)

Untuk memberikan analisis proyeksi pengeluaran bulanan, sistem menerapkan algoritma Simple Moving Average (SMA). Metode ini menghitung nilai rata-rata pergerakan dari data pengeluaran aktual dalam rentang periode waktu (n) tertentu guna meratakan fluktuasi data jangka pendek dan menyoroti tren arah pergerakan pengeluaran ke depan. Formula perhitungan matematis SMA ditunjukkan pada Persamaan 1:

$$SMA = \frac{P_1 + P_2 + \ldots + P_n}{n}$$

Dimana p adalah total nominal pengeluaran pada periode historis ke-n.

2.3. Perancangan Sistem dan Arsitektur

Aplikasi PFM ini dibangun dengan menerapkan arsitektur perangkat lunak Client-Server berbasis web guna memisahkan beban pemrosesan machine learning dari perangkat klien. Rancangan arsitektur integrasi sistem ini dapat dilihat pada Gambar 2.

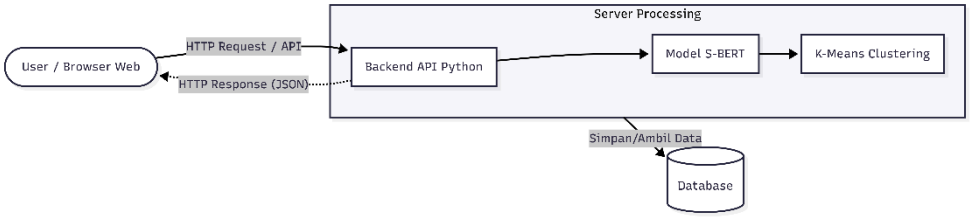

Gambar 2 Arsitektur integrasi sistem web dan model machine learning.

Secara fungsional, arsitektur dibagi menjadi dua lapisan utama:

1. Frontend (Antarmuka Pengguna): Dibangun dengan desain yang responsif. Pada lapisan ini, User berinteraksi dengan sistem untuk melakukan login, memasukkan deskripsi transaksi, dan melihat dasbor visualisasi (grafik tren hasil SMA dan pie chart persentase klasterisasi pengeluaran).
2. Backend (Logika API dan AI): Berperan sebagai pusat komputasi (server). Backend berbasis bahasa pemrograman Python menyediakan RESTful API yang bertugas menerima parameter HTTP Request (teks transaksi) dari frontend, mengeksekusi model S-BERT dan K-Means, mengelola operasi Create, Read, Update, Delete (CRUD) ke database, serta mereturn respon data format JSON kembali ke antarmuka pengguna.

2.4. Metode Pengujian

Gambar diberi nomor sesuai urutan presentasi (Gambar.1, dst.). Judul gambar yang diletakkan dibawah gambar dengan posisi tengah (centre justified). Font yang dipakai dalam judul gambar berukuran 9pt. Gambar harus diacu dan dirujuk dalam text.

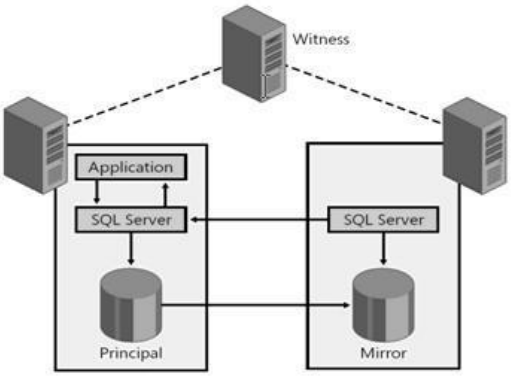

Gambar 1. Arsitektur Mirror Database

2.5. Rumus dan Persamaan

Persamaan-persamaan adalah pengecualian dari spesifikasi yang ditentukan dalam template ini. Anda perlu menentukan apakah persamaan Anda harus diketik menggunakan font Times New Roman atau Symbol (harap jangan menggunakan font lain). Untuk membuat persamaan bertingkat banyak, mungkin perlu memperlakukan persamaan tersebut sebagai gambar dan menyisipkannya ke dalam teks setelah makalah Anda diatur.

Nomori persamaan secara berurutan. Nomor persamaan, dalam tanda kurung, harus ditempatkan rata kanan, seperti dalam (1), menggunakan tab stop kanan. Untuk membuat persamaan Anda lebih ringkas, Anda dapat menggunakan solidus (/), fungsi exp, atau eksponen yang sesuai.

a ✱ *b* ● ■ ❍□❍

2.6. Pustaka

Penulisan pustaka menggunakan system IEEE Referencing Standard. Semua yang tertera dalam daftar pustaka harus dirujuk dalam tulisan atau paper.

3. Hasil dan Pembahasan

Rangkaian hasil penelitian berdasarkan urutan/susunan logis untuk membentuk sebuah cerite. Isinya menunjukan fakta/data dan jangan diskusikan hasilnya. Dapat menggunakan Tabel dan Angka tetapi tidak menguraikan secara berulang terhadap data yang sama dalam gambar, tabel dan teks. Untuk lebih memperjelas uraian, dapat mengunakan sub judul.

Pembahasan adalah penjelasan dasar, hubungan dan generalisasi yang ditunjukkan oleh hasil. Uraiannya menjawab pertanyaan penelitian. Jika ada hasil yang meragukan maka tampilkan secara objektif.

3.1. Spesifikasi

Gunakan tipe huruf Times New Roman pada seluruh naskah, dengan ukuran huruf seperti yang telah dicontohkan pada panduan penulisan ini. Jarak spasi adalah *single* dan isi tulisan atau naskah menggunakan perataan kiri-kanan (*justified*).

3.2. Ukuran Halaman

Ukuran halaman adalah A4 (210 mm x 297 mm). Margin halaman adalah 25 mm atas-bawah, kiri dan kanan.

3.3. Layout Naskah

Cara mudah membuat layout adalah dengan menggunakan panduan ini secara langsung.

3.4. Headings

Gunakan style heading dalam template ini secara langsung. Style sudah diformat sedemikian rupa sehingga memberikan jarak heading yang sesuai.

4. Kesimpulan

Dalam kesimpulan tidak boleh ada referensi. Kesimpulan berisi fakta yang didapatkan. Nyatakan kemungkinan aplikasi, implikasi dan spekulasi yang sesuai. Jika diperlukan, berikan saran untuk penelitian selajutnya.

Ucapan Terima Kasih (jika ada) *(Heading 5)*

Sebutkan nama pemberi dana dan pemberi fasilitas yang membantu (jika memang ada, dapat dituliskan).

References *(Heading 5)*

[1] A. Rosidi and A. Afriyudi, "Analisis Kendala Penggunaan Aplikasi PFM pada Generasi Milenial," Jurnal Sistem Informasi, vol. 12, no. 1, pp. 45-52, 2023.

[2] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing, 2019.

[3] I.S. Jacobs and C.P. Bean, “Fine particles, thin films and exchange anisotropy,” in Magnetism, vol. III, G.T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271-350.

[4] K. Elissa, “Title of paper if known,” unpublished.

[5] R. Nicole, “Title of paper with only first word capitalized,” J. Name Stand. Abbrev., in press.

[6] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, “Electron spectroscopy studies on magneto-optical media and plastic substrate interface,” IEEE Transl. J. Magn. Japan, vol. 2, pp. 740-741, August 1987 [Digests 9th Annual Conf. Magnetics Japan, p. 301, 1982].

[7] M. Young, The Technical Writer’s Handbook. Mill Valley, CA: University Science, 1989.